

扁平模型（Flat Baseline, M0–M4）完整流程详解

本文目的：面向完全不了解本项目的读者，把「扁平模型」从下载数据、去云、洗数据、特征工程、合并、建模、参数选择、回测训练，到结果与分析，**每一步全部写清楚**。

一句话定位：扁平模型是本论文的核心实证对照层。它把金融、遥感、航运三类数据「拍平（flatten）」拼成一张大宽表，喂给两个机器学习模型（Ridge、XGBoost），逐层加数据（消融阶梯 M0→M4），检验「每一类新数据对预测下周油价到底有没有用」。

最后更新：2026-07-28（路径改为 [最新待整理/](#)；澄清矩阵 365×213 与 GFW 扁平/深度滞后分层；补主分析 vs 稳健性、RQ2 桥接与文档索引；主结果数字仍为 2026-07-03/05 L4_tuned）

对应实验记录：[00_admin/最新待整理/flat_baseline_log.md](#)
变量清单：[00_admin/最新待整理/2026-07-28_扁平模型变量清单.md](#)
进度总览：[00_admin/最新待整理/2026-07-15_研究方案与进度总览.md](#)
深度对照：[deep_model_full_walkthrough_CN.md](#)
代码 / 数据：[04_code/](#) · [03_data/](#)

目录

- 1. 项目要解决什么问题
- 2. 第 0 步：原始数据下载
- 3. 第 1 步：遥感去云与月度合成
- 4. 第 2 步：数据清洗与特征工程
- 5. 第 3 步：合并成统一矩阵
- 6. 第 4 步：缺失值与异常值处理
- 7. 第 5 步：建模数据组装
- 8. 第 6 步：模型与参数选择
- 9. 第 7 步：回测协议（怎么训练的）
- 10. 第 8 步：主结果
- 11. 第 9 步：怎么分析结果
- 12. 第 10 步：稳健性检验
- 13. RQ1 回答
- 14. 主分析 vs 稳健性 + 通向 RQ2
- 15. 文档索引与复现

1. 项目要解决什么问题

预测目标：下一周的 Brent 原油现货价 P_{t+1} （单位：美元/桶）。

训练方式：模型不直接预测价格，而是预测对数收益 $r_{t+1}=\ln(P_{t+1}/P_t)$ ，再还原成价格 $\hat{P}_{t+1}=P_t \cdot e^{\hat{r}}$ 。这样做是因为价格本身非平稳（有趋势），对数收益更平稳、更适合建模。

核心科学问题：

- **RQ1**: 卫星遥感、航运数据能不能超过纯金融模型、能不能超过「随机游走」这个强基准？
- **RQ2**: 把多种数据简单「拍平拼接」够不够？还是需要更聪明的「模态感知融合」？

消融阶梯（逐层加数据，看每类数据的增量价值）：

模型	用了什么数据	通俗理解
M0	什么都不学	「下周价 = 本周价」，随机游走，最朴素但极强的基准
M1	金融/宏观（31 列）	价格、库存、VIX、黄金、汇率、地缘风险等
M2	M1 + 遥感（55 列）	加卫星特征：11 个油站的植被/水体/建成区/裸土/夜光
M3	M1 + 航运（113 列）	加船运特征：6 个咽喉道的油轮流量、AIS 船舶存在
M4	M1 + M2 + M3	金融+遥感+航运全部一起

每个模型用两种算法：

- **Ridge**：带 L2 正则的线性回归，稳健但怕高维噪声
- **XGBoost**：梯度提升树，能抓非线性，对高维冗余更鲁棒

2. 第 0 步：原始数据下载

三类模态各有独立的数据来源，全部存在 `03_data/raw/`（原始层，`raw/` 整个目录不进 git）。

2.1 M1 金融/宏观数据

存放：`03_data/raw/01_market_financial/`

子目录	来源	内容	频率	下载方式
EIA/	美国能源信息署	Brent/WTI 日频现货价 (.xls)、周报 WPSR（库存/产量/炼厂等）	日频/周频	手工下载 .xls
FRED/	美联储经济数据库	VIX、美元指数、10 年美债、联邦基金利率、工业原料指数	日频/月频	手工 + 在线 API
Yahoo/	Yahoo Finance	标普500 (^GSPC)、原油波动率 (^OVX)、Brent 期货 (BZ=F)、加元汇率 (CADUSD=X)、黄金 (GC=F)	日频	yfinance
Other/	学者维护	Dallas Fed Kilian 全球活动指数 (igrea)、Caldara-Iacoviello 地缘政治风险 (GPR)	月频/日频	手工下载

下载脚本：`download_m1_raw.py`。构建脚本 `build_m1_weekly.py` 默认离线读本地文件；加 `--online` 可在线补抓 FRED / yfinance（带超时重试）。

2.2 M2 遥感数据

存放：`03_data/raw/02_sentinel2/Channel B/`（GEE 导出，不进 git）

文件	传感器	内容	起始
<code>sentinel2_oil_sites_monthly_indices_..._11aoi.csv</code>	Sentinel-2 SR Harmonized	NDVI/NDWI/NDBI/BSI 月度光学指数	2017-04
<code>viirs_oil_sites_monthly_nightlights_..._11aoi.csv</code>	VIIRS DNB	夜间灯光 NTL 月度	2014-01

文件	传感器	内容	起始
sentinel2_..._watermask_..._11aoi.csv (稳健性版)	Sentinel-2	加水体掩膜 + MNDWI	2017-04

下载方式：Google Earth Engine (GEE) JavaScript 脚本导出到 Google Drive，再同步到本地。脚本如 [extract_sentinel2_monthly_indices_gee.js](#)、[extract_viirs_monthly_nightlights_gee.js](#)。

11 个油基础设施 AOI (5 km 圆缓冲)：

短名	全名	类型	国家
Houston	休斯顿航道	港口	美国
Rotterdam ★	鹿特丹港	港口	荷兰
NingboZhoushan	宁波舟山港	港口	中国
Jamnagar	贾姆讷格尔炼厂	炼厂	印度
Jurong	新加坡裕廊岛	炼厂	新加坡
Ulsan	蔚山炼厂	炼厂	韩国
Basra	巴士拉油码头	码头	伊拉克
Fujairah ★	富查伊拉油码头	码头	阿联酋
Kharg	哈尔克岛码头	码头	伊朗
RasTanura ★	拉斯坦努拉码头	码头	沙特
Yanbu	延布出口码头	码头	沙特

★ = 文献支撑最强的核心油站，4 个站的 NTL 夜光异常构成后面的「literature 精选臂」。

2.3 M3 航运数据

存放：[03_data/raw/03_shipping/](#)

来源	文件	内容	频率
IMF PortWatch	portwatch_chokepoints_daily.csv	6 咽喉道过境（油轮艘次/运力）	日频
IMF PortWatch	portwatch_ports_daily.csv	出口/进口枢纽 tanker 吨位	日频
Global Fishing Watch	gfw_chokepoint_vessel_presence_monthly.csv	6 咽喉 AIS 船舶存在	月频

6 个咽喉道：hormuz（霍尔木兹）、suez（苏伊士运河）、malacca（马六甲）、mandeb（曼德海峡）、panama（巴拿马运河）、cape（好望角）。

3. 第 1 步：遥感去云与月度合成（仅 M2）

去云是遥感特有的处理，全部在 **GEE 导出阶段**完成（构建脚本读到的已是去云后的月度指数）。

3.1 Sentinel-2 光学（NDVI/NDWI/NDBI/BSI）去云三步

1. 场景预筛：整景云量 `CLOUDY_PIXEL_PERCENTAGE ≤ 60`（参数 `CLOUD_FILTER`），先扔掉大面积云的影像。
2. 双重云掩膜（逐像元）：
 - `s2cloudless` 云概率 `< 40`（参数 `CLD_PRB_THRESH`）判为晴空
 - 再叠加 `SCL` 场景分类掩膜，剔除 `SCL ∈ {3 云影, 8 中概率云, 9 高概率云, 10 卷云, 11 雪/冰}`
3. 月度中值合成：把当月所有晴空像元取 **median（中值）合成**（中值对残云最鲁棒）→ 在 5 km AOI 内做 `reduceRegions(mean)` 求均值，尺度 `scale=20m`。

质量记录（不入模，仅诊断）：`valid_obs_count`（当月进合成的有效场景数）、`cloud_probability`。这两个是「云多不多」的诊断量，不作为预测特征（避免把「云量」误学成价格信号）。

3.2 VIIRS 夜光（NTL）处理

1. 质量掩膜：剔除 `avg_rad < 0`（杂散光/数据伪影）。
2. 区域统计：5 km AOI 内 `reduceRegions(mean/max/stdDev)`，尺度 `scale=500m`，取 `avg_rad` 均值作为夜光水平。

VIIRS 连续性好（自 2014 起），几乎无云缺问题；Sentinel-2 受云影响，早期部分站点有月缺。

3.3 波段与公式

指数	公式（GEE 波段）	含义
NDVI	$(B8-B4)/(B8+B4)$	植被绿度
NDWI	$(B3-B8)/(B3+B8)$	水面/湿度
NDBI	$(B11-B8)/(B11+B8)$	建成区/不透水面
BSI	$((B11+B4)-(B8+B2))/((B11+B4)+(B8+B2))$	裸土/堆场
NTL	VIIRS DNB <code>avg_rad</code> 均值	夜间灯光/活动强度

3.4 B4 水体掩膜稳健性版（可选）

针对 Basra/Kharg 等离岸码头 NDWI 被水面主导的问题，重跑 GEE 加水体掩膜：逐影像先算 `MNDWI = (B3-B11)/(B3+B11)`，`MNDWI > 0` 判为水体，从 NDVI/NDBI/BSI 中掩除水面像元（只留陆地），输出 `s2_land_px`（陆地像素占比）。

4. 第 2 步：数据清洗与特征工程

三个模态各有一个构建脚本，把原始数据洗成无泄漏的周频表，统一以**每周五（W-FRI）**为时间轴。

4.1 M1 金融：build_m1_weekly.py

输出：`m1_weekly_features.csv`（1043 周 × 35 列，2006–2025；建模裁到 2019–2025）

处理流程：

1. 生成 2006–2025 每周五骨架
2. 日频→周频：`resample("W-FRI").last()` 取每周五最后值

- 3. **EIA 周报**: 对齐到报告周五 → 整体 **shift(+1 周)** (周报周三才发布, 防泄漏)
- 4. **月频宏观**: 月末对齐 + 前向填充到周频 → **shift(+1 或 +5 周)**
- 5. **派生变量**: 对数收益、价差、库存变化、换月哑变量等

发布滞后 (防泄漏, 关键):

来源	周频化	滞后
日频价格/宏观	周五最后值	0 (周五收盘可得)
EIA 周报 (WPSR)	报告周五对齐	+1 周
GPR 地缘风险 (月频)	月末+ffill	+1 周
Kilian REA / IMF 工业原料 (月频)	月末+ffill	+5 周

入模 **31 列** (2026-07 精简后):

分组	变量
价格/派生 (5)	brent_price, wti_price, brent_log_return, wti_log_return, brent_wti_spread
EIA 周报 (12, +1w)	crude_stocks_excl_spr, cushing_stocks, crude_production, crude_imports, crude_exports, refinery_crude_input, refinery_utilisation, gasoline_supplied, distillate_supplied, jet_fuel_supplied, crude_stocks_change, cushing_stocks_change
宏观金融 (5)	vix, dollar_index, treasury_10y, fed_funds_rate, sp500_log_return
衍生市场/宏观 (9)	ovx, gpr, gold_return, global_econ_activity, nonoil_industrial_commodity, brent_f1_spot_log_basis, brent_roll_week, cadusd_log_return, dgs10_change

4.2 M2 遥感: **build_m2_weekly.py**

输出: **m2_weekly_features.csv** (365 周 × 155 列, 2019–2025)

核心洗数据 = 把原始 **level** 转成「站点内去季节标准化距平 **anom**」(这是 M2 入模的主力形态)。分两步, 全部用 **expanding** 窗口、只用过去 (无泄漏):

- 1. **去季节**: 对每个 (站点, 指标), 按「月份」取历史同月气候态 **clim** (如所有 1 月的平均), 残差 **resid = level - clim**。正 = 比往年同月更绿/更亮。
- 2. **站点内 z-score 标准化**: **anom = (resid - μ)/σ**, 其中 μ、σ 用 **expanding(min_periods=12)** (至少 12 个月历史)。得到「偏离了几个标准差」。

因为需要 ≥12 个月历史, 每个序列前 **12 个月** 的 **anom** 是 **NaN**, 加上早期云缺, 部分站点 (Jurong/Ningbo/Ulsan) 前段缺失更多。

三种形态对比:

形态	含义	是否入模
level	原始月度值	✗ 主分析不用 (尺度不可比、含季节)
anom	站点内去季节 z-score 距平	✓ 入模主力 (55 列)
mom	月环比差分	✗ 仅 EDA 表

月→周对齐 (**as-of join**, 不用假 **ffill**):

参数	值	含义
OBS_DAY=15	15	代表观测日 = 月初+14 天
PUB_LAG_DAYS=15	15	保守可得日 = 月末+15 天（模拟发布延迟）
对齐	merge_asof(backward)	每周五取「已发布」的最近月度观测
MAX_AGE_DAYS=100	100	超 100 天视为模态不可用

每周同时携带 **age**（陈旧天数）和 **mask**（是否可用），让缺失/陈旧显式可见，而不是把月值复制成多个相同的假周值。

入模 **55 列**：5 指数 × 11 AOI，命名 {指数}_anom_{站点}（如 **NTL_anom_Fujairah**）。不入模：55 个 level、22 个 age、22 个 avail（时效非信号或窗内近零方差）。

4.3 M3 航运：aggregate_shipping_to_weekly.py

输出：m3_weekly_features.csv（750 周 × 123 列；建模裁 2019–2025）

处理流程：

1. PortWatch 日频 → resample("W-FRI").sum() 周求和 → shift(+1 周)

2. GFW 月频 → 月末对齐 + ffill 到周频 → shift(+4 周)

3. 三源用 union 索引拼接（修复旧版 inner-join 掉样本 bug：727→362）

4. 派生变量：tanker_share（油轮占比）、n_tanker_wow_pct（周环比）、avg_tanker_size（平均吨位）、跨咽喉汇总等

发布滞后（扁平臂；与深度图勿混写）：

来源	周频化	滞后	说明
PortWatch（日频）	日→周五求和	+1 周	扁平 M3 与深度图咽喉节点共用 PW
GFW（月频 presence）	月末+ffill	+4 周	仅扁平 113 列 中的 gfw_*
GFW event / 航次 / O-D（深度图）	事件→W-FRI	+2 周	见深度 walkthrough； 不是 扁平表列
GFW SAR 暗船	月末+ffill	+4 周	深度图节点特征； 未进 扁平主模型

旧文档若笼统写「GFW +2 周」，那是深度图 **event/航次** 流，**不适用于**扁平 GFW presence。

入模 **113 列**（full tier，主模型）：

来源	列数	内容
GFW	49	6 咽喉 × (total_hours, total_vessels, cargo_hours, mom_pct, bunker_hours, other_hours, other_share, mean_presence) + 1 汇总
PortWatch 咽喉	~57	6 咽喉 × (n_tanker, n_total, capacity_tanker, capacity, tanker_share, tanker_cap_share, avg_tanker_size, n_tanker_wow_pct, capacity_tanker_4w_ma) + 3 汇总
PortWatch 港口	7	出口/进口枢纽吨位、净额、不对称、对数比等

为什么用 113 列 full 而不是 38 列 core? 见 §12.2 —— 实测 core 对 XGB 最弱且不显著, SHAP 显示最有价值的派生列全在 core 之外。

5. 第 3 步: 合并成统一矩阵

`build_feature_matrix.py` 把三个周频表按周五对齐、拼成唯一入模数据。

输出: `03_data/processed/merge/outputs/weekly_feature_matrix.csv`

维度 (2026-07-28 磁盘核对): 365 周 × 213 列 = `week_ending_friday` + 212 数据列 (2019-01-04 ~ 2025-12-26)。下文表格仍按「212 数据列」拆模态 (不含日期索引)。

模块	列数	说明
日期索引	1	<code>week_ending_friday</code> (非特征)
M1 金融	31	特征
M2 遥感	55	仅 55 个 anom (level/age/avail 不并入)
M3 航运	113	full tier 全部航运列
mask (模态可用性)	11	<code>avail_*</code> , 不作特征 (窗内近零方差)
target	2	<code>target_price_next</code> 、 <code>target_log_return_next</code> , 建模时前瞻生成, 不作特征

防泄漏复查: 合并层不重复施加滞后 (EIA 已在 M1 层 +1w, merge 设 `EIA_WPSR_LAG_WEEKS=0`, 避免变成 +2w); 三模态统一「各自滞后、merge 仅复查」, 无泄漏自检全部通过。

为什么窗口是 2019–2025: 三个模态齐全的最大交集。PortWatch 只覆盖 2019+, 所以标准比较窗从 2019 开始。长历史见 `weekly_feature_matrix_full.csv` (~1067 周, 主分析未用)。

变量明细: 见 `2026-07-28_扁平模型变量清单.md`。

6. 第 4 步: 缺失值与异常值处理

(以下数字为实测统计: 365 周 × 212 数据列 ≈ 77,380 个单元格; CSV 另含 1 列日期索引)

6.1 缺失值总览

指标	数值
总 NaN	553 个 (占 0.71%)
无穷值 inf	0
完全无缺失的列	134 / 212

6.2 缺失按模态分组

模态	列数	总 NaN	占比	缺在哪
M1 金融	31	0	0%	无缺失

模态	列数	总 NaN	占比	缺在哪
M2 遥感	55	480	2.4%	早期云缺 + 12 月历史要求
M3 航运	113	71	0.2%	周环比首周无法算
mask	11	0	0%	无缺失
target	2	2	—	最后一周无「下周价」

M2 缺失集中在 3 个站点早期：Jurong（各指数 59 周）、NingboZhoushan（37 周）、Ulsan（24 周）。根因是 anom 需 ≥12 月历史 + Sentinel-2 早期云缺。

6.3 缺失怎么处理

在建模数据组装层（data.py 的 fill_features）：

```
X.ffill().fillna(0.0)
```

步骤	做法	理由
① ffill()	用历史值前向填充	无泄漏（只用过去）
② fillna(0.0)	残留 NaN 填 0	中性值（对 z-score 距平，0 = 无异常）

关键：填充后的残留 NaN 只落在 warm-up（前 104 周），不落在测试期 → 所有 M0–M4 落在完全相同的 257 个测试周，RMSE 差异只来自特征内容。

6.4 异常值怎么处理

没有做显式的删除/截断（winsorize），而是靠「变换 + 模型正则化」间接控制。实测极端值：

类型	范围	处理
RS 距平 z-score	−5.96 ~ 9.21（43 个	z
周环比 wow_pct	最大 ±158%	保留（真实流量剧变）
inf	0	源头拦截：距平 ±inf→NaN；n_tanker=0 时 avg_size→NaN

间接抗异常的三层机制：

- 1. 变换：遥感用站点内 z-score 距平（去季节去尺度）、金融用对数收益（而非价格水平）
- 2. Ridge：StandardScaler 标准化 + 强 L2 正则（α 最高 1000）压极端值
- 3. XGBoost：树模型按分裂点切分，对离群点/量级天然鲁棒

保留真实极端值是刻意的——它们对应疫情、红海/Houthi 等真实事件，删掉反而丢信号。

7. 第 5 步：建模数据组装（data.py）

7.1 选列（按模态）

按字典的 modality 字段选列，永不选 target_* 和 avail_*（mask）。

7.2 lag 展平 (lookback=4)

每个特征展平成过去 4 周：`{变量}_lag0` (本周)、`_lag1`、`_lag2`、`_lag3` (3 周前)。入模维度 = 原始列数 $\times$ 4。

模型	原始特征列	$\times 4$ lag	入模维度
M0	0 (规则基准)	—	—
M1	31	$\times 4$	124
M2	31+55=86	$\times 4$	344
M3	31+113=144	$\times 4$	576
M4	31+55+113=199	$\times 4$	796

7.3 目标构造

- 训练标签：`r_next = ln(P.shift(-1)/P)`，索引在 `t`，代表 `r_{t+1}`
- 预测还原： $\hat{P}_{t+1} = P_t \cdot e^{\hat{r}}$
- 特征中永不含 target 和 mask

8. 第 6 步：模型与参数选择

8.1 M0 随机游走 (内嵌规则，不是训练出来的模型)

$$r_{\text{hat}} = 0 \rightarrow P_{\text{hat}} = P_t \quad (\text{「下周价} = \text{本周价」})$$

每周自动输出，作为所有模型的基准。M0 RMSE $\approx$ **4.152**。

8.2 Ridge (线性 + 强正则)

Pipeline (只在训练折内 fit，防泄漏)：

$$\text{VarianceThreshold}(0.0) \rightarrow \text{StandardScaler}() \rightarrow \text{Ridge}(\alpha)$$

- 默认 `alpha=10.0`
- 调参网格：`alpha ∈ {0.1, 1.0, 10.0, 100.0, 1000.0}`
- 选择逻辑：维度越高越需要大 α ；L4 不调参 RMSE 5.91，调参后降到 4.26

8.3 XGBoost (梯度提升树)

Pipeline：`VarianceThreshold(0.0) → XGBRegressor` (树模型不需要标准化)

默认参数：`n_estimators=300`, `max_depth=3`, `learning_rate=0.05`, `subsample=0.8`, `colsample_bytree=0.8`, `reg_lambda=1.0`

调参网格 ($2 \times 2 \times 2 = 8$ 组)：

参数	候选
max_depth	2, 3
learning_rate	0.03, 0.05
n_estimators	200, 400
subsample	0.8（固定）
colsample_bytree	0.8（固定）
reg_lambda	1.0（固定）

防过拟合设计（小样本高维尤其重要）：浅树（depth 2–3）、行/列子采样 80%、L2 正则。

8.4 参数怎么选（内层验证）

每个重训折内：

训练折（如 200 周）

├ 前段 → fit

└ 尾部 52 周 → 验证，选 RMSE 最低的超参

若训练折 < 82 周（52+30）→ 用默认参数

选出最优超参后，用全部训练折重训，再预测。调参绝不看测试集。

9. 第 7 步：回测协议（具体怎么训练的）

用 **expanding rolling-origin**（扩展窗口滚动起点）**walk-forward** 回测。代码：
[04_code/src/backtest/rolling.py](#)。

9.1 关键参数

参数	值	含义
总周数	365	2019-01-04 ~ 2025-12-26
lookback	4 周	每特征展平成本周+前3周
min_train	104 周	前 104 周只攒数据不预测（≈2 年 warm-up）
retrain_every	13 周	每季度重训一次
val_weeks	52 周	训练集尾部 52 周做内层验证
测试周	257 周	约 2021–2025
seed	42	随机种子

9.2 核心思想（打比方）

想象你是 2021 年初的分析师，每周五预测下周油价：只能用「今天之前」的数据训练；随时间推进历史越来越多（窗口扩展）；不是每周重训，而是每季度（13 周）更新一次模型。

9.3 分步走一遍

阶段一（第 1–104 周，warm-up）：只积累数据，不预测。

阶段二（第 105 周，第一次预测）：

- 1. 取训练数据 = 第 1~104 周（104 个样本）
- 2. 内层调参：训练集分「前段 fit + 尾部 52 周验证」，Ridge 试 5 个 α 、XGB 试 8 组参数，各选验证 RMSE 最低的
- 3. 用最优参数在全部 104 周上正式训练 Ridge 和 XGB
- 4. 预测第 105 周的下周油价
- 5. 记录 M0 基准

阶段三（第 106–117 周）：沿用第 105 周的模型逐周预测，不重训。

阶段四（第 118 周，第二次重训）：(118-104)%13==0 触发重训，训练数据 = 第 1~117 周（更多了），重新调参重训。

循环到底：

第105周 训练(104样本) → 预测105~117
第118周 训练(117样本) → 预测118~130
...
最后一次 训练(~360样本) → 预测最后几周

9.4 精确回答「训练了几个/训练周/验证周」

问题	答案
训练了几个模型	每个 fold 训 2 个 (Ridge+XGB)；约 20 个 fold × 2 ≈ 40 次拟合；M0 不训练
训练的周数	扩展式：首次 104 周 → 末次 ~360 周
验证的周数	每次训练集尾部 52 周（选超参后再用全训练集重训）
测试的周数	257 周（2021–2025），M0–M4 共用

9.5 为什么这样设计

设计	目的
只用过去训练	严格无泄漏（walk-forward）
扩展窗口	模拟真实：越往后历史越多
min_train=104	首次预测就有 2 年数据 + 够跑 52 周验证 + 对齐 M2 距平 12 月历史
retrain_every=13	每季度更新，平衡时效与算力
M0–M4 同协议	差异只来自数据/模型，公平

9.6 文献支撑（这是石油预测标准范式）

文献	用的回测方法
P053 Alquist, Kilian & Vigfusson (2013)	实时对齐 + 递归/扩展窗 + DM 检验；随机游走为强基准

文献	用的回测方法
P054 Baumeister & Kilian (2015)	实时递归预测组合
P072 Costa et al. (2021)	扩展窗口伪样本外
P076 Yilmaz & Zehir (2026)	滚动样本外 + 多步长 + DM
P025 Hao & Wang (2023, 遥感→油价)	递归实时样本外 + Clark–West

10. 第 8 步：主结果

主基线 (L4_tuned, 257 测试周, M0 RMSE=4.152):

模型	RMSE (\$/桶)	skill vs M0	CW_p vs M1 (加模态是否显著)	结论
M0_RW	4.152	—	—	随机游走基准
M1_Flat_Ridge	4.256	−2.5%	—	金融基线
M1_Flat_XGB	4.368	−5.2%	—	最强 RMSE 之一
M2_Flat_Ridge	4.414	−6.3%	0.474	加遥感, 线性不显著
M2_Flat_XGB	4.440	−6.9%	0.085 ❌	加遥感, 边缘不显著
M3_Flat_Ridge	4.430	−6.7%	0.264	加航运
M3_Flat_XGB	4.429	−6.7%	0.0002 ✅	加航运, 高度显著
M4_Flat_Ridge	4.525	−9.0%	0.314	全模态, 线性不显著
M4_Flat_XGB	4.507	−8.6%	0.009 ✅	全模态, 显著但 RMSE 最差

三个核心结论:

- 没有任何模型赢过 M0 (skill 全负) —— 周度油价极接近随机游走, 这是预期内的强基准。
- 单加遥感 M2 不显著 (0.085); 单加航运 M3 显著 (0.0002); 全模态 M4 显著 (0.009)。
- 反直觉点: M4 显著但 RMSE (4.507) 反而比 M1 (4.368) 差——因为 RMSE 问「最终误差大不大」, Clark-West 问「扣掉大模型多估参数的噪声惩罚后, 新特征本身有没有方向性信号」, 是两件事。有信号, 但扁平拼接吃不动。

11. 第 9 步：怎么分析结果

11.1 三层证据链

- 第一层 (精度): RMSE / MAE / skill vs M0

→ 「误差多大? 赢过 M0 吗? 」

第二层 (显著性): DM / Clark–West

→ 「改善是显著还是偶然? 」

第三层 (解释): SHAP / LOAO / LOMO

→ 「靠什么变量? 去掉谁影响大? 」

11.2 指标与检验分工

工具	用途	类型
RMSE / MAE	平均预测误差	精度指标
skill vs M0	1 – RMSE/RMSE_M0	相对随机游走
DirAcc	涨跌方向命中率	精度指标
Diebold–Mariano	vs M0（非嵌套）	计量经济学检验
Clark–West	vs M1（嵌套）	嵌套模型正确检验
SHAP	哪些变量/模态被用	ML 可解释性（≠因果、≠显著性）

为什么 M0 用 DM、M1 用 CW：M2/M3/M4 是 M1 加特征的「嵌套扩展」，嵌套时标准 DM 有偏（大模型多估了真值为 0 的参数），Clark-West 专门校正这个偏差。M0 与模型非嵌套，用 DM。

11.3 「显著但 RMSE 更差」怎么解读（M4）

- **RMSE**：最终误差 → M4(4.507) > M1(4.368)，加特征反而更差
- **Clark-West**：扣掉噪声惩罚后，新增模态有无方向性信号 → p=0.009 显著

比喻：新增模态像一个啰嗦的分析师，有一点真信号（CW 显著），但夹带太多废话（RMSE 变差）。→ 扁平拼接吃不动，需要模态感知融合（RQ2 动机）。

12. 第 10 步：稳健性检验（全部已跑）

12.1 各模态扩展分析一览

分析	模态	关键发现
lookback sweep	M1	调参最关键；Ridge 随 lookback 恶化，XGB 免疫
literature 臂（4 列 NTL）	M2	XGB CW=0.022  ，少而精 > 全 55 列
leave-one-AOI-out	M2	各站
SHAP	M2	NDVI/NDWI 居前；金融特征仍主导 Top-5
C2 降维（PCA/ElasticNet）	M2	PCA 对 XGB 增益最大（去共线）
B4 水体掩膜	M2	XGB CW 0.085→0.028  （去水面噪声后显著）
2×2 稀疏性六臂	M2	砍站或砍指标任一都跨入显著（aoi4 最强 0.0055）
leave-one-channel-out	M3	core(38) 不显著；full/tanker/portwatch 显著
SHAP	M3	Top：hormuz tanker 占比、suez 周环比（红海机制）
leave-one-modality-out	M4	M1-only RMSE 全局最优；加 M2 到 M1+M3 反而变差
SHAP 模态占比	M4	航运 51.8% > 金融 33.7% > 遥感 14.5%

12.2 为什么航运用 113 列 full 而不是 38 列 core

leave-one-channel-out 实测：

航运子集	XGB RMSE	CW_p vs M1	显著
core (38)	4.476	0.096	✗
full (113)	4.429	0.0002	✓
tanker-only	4.343	0.0018	✓
portwatch-only	4.356	0.0003	✓

- **core** 是最弱且唯一不显著的
- SHAP Top-10 全是 core 精选丢掉的派生列 (tanker_share、n_tanker_wow_pct、tanker_cap_share、avg_tanker_size)
- 结论：人工 **core** 精选恰好删掉了 **XGB** 最看重的航运信号 → 改用 full
- 这与 M2 「少而精」 方向相反，是 M3 特有现象

13. RQ1 回答

RQ1： 卫星遥感、航运数据能不能超过纯金融模型（M1）、能不能超过「随机游走」（M0）？

13.1 能否超过随机游走 M0？

不能。 所有 M1–M4 配置的 skill vs M0 均为负（RMSE 均高于 M0 的 4.152）；最强模型 M1_Flat_XGB（4.368）仍比 M0 差 5.2%。周度 Brent 极接近随机游走，与 P053 文献结论一致——这不是模型失败，而是说明 M0 本身就是极强的比较基准。

13.2 能否超过金融基线 M1？

分模态，结论不同：

模态	vs M1 (XGB, 主规格)	RMSE vs M1_Flat_XGB (4.368)	RQ1 判断
M2 遥感	CW_p = 0.085 ✗ 不显著	4.440 (更差)	不能超过 M1
M3 航运	CW_p = 0.0002 ✓ 高度显著	4.429 (略差)	CW 显著，但 RMSE 未改善
M4 全模态	CW_p = 0.009 ✓ 显著	4.507 (最差)	CW 显著，但 RMSE 明显更差

- **遥感 (M2)：** 扁平拼接全量 55 列不能提供相对 M1 的显著嵌套增量；Ridge 亦不显著 (CW_p = 0.474)。稳健性显示信号存在但被稀释——literature 4 列夜光 (CW_p = 0.022 ✓)、水体掩膜版 anom-55 (CW_p = 0.028 ✓)、稀疏性实验 (砍站/砍指标) 可跨入显著，说明有微弱信息，但全量扁平吃不动。
- **航运 (M3)：** full 113 列 XGB 对 M1 高度显著 (CW_p = 0.0002)，SHAP 指向霍尔木兹 tanker 占比、苏伊士周环比 (红海机制)；但 RMSE 仍略高于 M1_Flat_XGB，有信号、未转化为精度优势。
- **全模态 (M4)：** XGB 嵌套增量显著 (CW_p = 0.009)，主要来自 M3 full；加 M2 到 M1+M3 反而使 XGB 变差 (LOMO：M1-only RMSE 全局最优)。多模态扁平拼接不能同时改善精度与显著性。

13.3 综合结论

扁平模型下，没有任何配置在 **RMSE** 上同时战胜 **M0** 和 **M1**；航运与全模态在 Clark–West 意义下相对 M1 有显著增量信号，但高维拍平把信号淹没在噪声里，无法转化为样本外精度改善。RQ1 的答案是有条件的否定——替代数据不是没用，而是简单扁平拼接不足以释放其价值 (→ RQ2 动机)。

14. 主分析 vs 稳健性 + 通向 RQ2

14.1 主分析口径（正式答案；不挑最优）

层	主分析口径	为什么是它
M0	随机游走 $\hat{P} = P_t$	理论基准
M1	金融 31 列, L4_tuned	导师设定 4 周 + 全量金融
M2	遥感全 11 站 anom-55	最朴素「全塞」, 不人工精选
M3	航运 full 113 列	全量航运 (core 精选对 XGB 反而次优)
M4	M1+M2+M3 全量	全模态扁平拼接

稳健性臂 (literature / aoi4 / 水体掩膜 / LOAO / LOCHO / LOMO / lookback sweep 等) 只用来回答「换子集或去噪后结论还在不在」——**加固主结论, 不升级为主分析** (否则 = p-hacking, 且会自拆「扁平吃不动 → 需要融合」的 RQ2 主线)。

14.2 通向 RQ2（深度表示级融合）

扁平层的诚实负结果（无一击败 M0；M2 全量不显著；M3/M4 有 CW 信号但 RMSE 不改善）正是方法集成层的动机。下一层见：

- **流程详解**: [deep_model_full_walkthrough_CN.md](#)
- **RQ2 配对表** (同信息集 Flat XGB vs Deep): 进度总览 §2.6 / 深度 walkthrough §12.5
 - 要点: 深度在 M3/M4 (含航运) 上显著优于扁平 XGB; 主模型仍为 **Gated**; xattn 单 seed 强但不稳

15. 文档索引与复现

用途	路径
本文件 (扁平完整流程)	00_admin/最新待整理/flat_baseline_full_walkthrough_CN.md
扁平实验数字主日志	00_admin/最新待整理/flat_baseline_log.md (§7–§12; §13 深度首跑为 lb=8 历史 , 正式深度结果见 deep walkthrough)
变量清单	00_admin/最新待整理/2026-07-28_扁平模型变量清单.md
进度总览	00_admin/最新待整理/2026-07-15_研究方案与进度总览.md
深度 walkthrough	00_admin/最新待整理/deep_model_full_walkthrough_CN.md
特征矩阵	03_data/processed/merge/outputs/weekly_feature_matrix.csv
扁平入口	04_code/scripts/flat/run_baseline.py + flat/M{1..4}_Flat/
产物	05_outputs/baselines/Flat/M*_Flat/

```
# 扁平主基线 (示例)
python3 04_code/scripts/flat/run_baseline.py --modality M1
python3 04_code/scripts/flat/run_baseline.py --modality M2
python3 04_code/scripts/flat/run_baseline.py --modality M3
```

```
python3 04_code/scripts/flat/run_baseline.py --modality M4  
# 各层 sweep / SHAP / robustness 见 flat/M*_Flat/
```